


Data Science - Transferarbeit: Machine Learning Pipeline



1. Hintergrund und Zielsetzung

Im Rahmen dieser Transferarbeit sollen Sie einen realen Datensatz eigenständig importieren, analysieren und aufbereiten, um eine praxisnahe Machine-Learning-Lösung zu entwickeln. Der Fokus liegt auf der technischen und analytischen Umsetzung: Von der Use-Case-Definition über die Datenbereinigung und Feature-Engineering bis hin zur Modellwahl, dem Training und der kritischen Auswertung. Die Studierenden erarbeiten die einzelnen Schritte eigenständig und dokumentieren diese direkt im Jupyter Notebook. Der Engineering- und Analyse-Anteil (saubere Datenprozessierung, fundierte Modellwahl, korrekte Evaluation) wird höher gewichtet als die reine Business-Interpretation.

2. Lernziele

- Import, Analyse und Aufbereitung eines realen Datensatzes
- Ableitung einer geeigneten ML-Aufgabenstellung (Use-Case-Analyse)
- Erstellung und Auswahl relevanter Features aus Rohdaten
- Wahl, Training und Evaluation eines geeigneten ML-Modells
- Kritische Beurteilung der Ergebnisse und Benennung von Verbesserungspotenzial
- Dokumentation und Präsentation der Analyse vor der Klasse

3. Aufgabenstellung

3.1 Datensatz-Auswahl

Wählen Sie **einen** der folgenden fünf öffentlich verfügbaren Datensätze (z. B. von Kaggle oder UCI ML Repository):

- **A – E-Commerce Shipping:** ~11'000 Bestellungen. Ziel: Pünktliche Lieferung vorhersagen.
- **B – Telco Customer Churn:** ~7'000 Kunden. Ziel: Vertragskündigung vorhersagen.
- **C – Online Retail II:** ~1 Mio. Transaktionen. Ziel: Kundensegmentierung oder Return-Wahrscheinlichkeit.
- **D – Credit Card Fraud:** ~284'000 Transaktionen. Ziel: Betrugsfälle erkennen (stark unausgeglichene Daten).
- **E – House Prices:** ~1'500 Einträge. Ziel: Immobilienpreise prognostizieren.

3.2 Implementierungsschritte

Die Arbeit ist in vier sequenzielle Analyse-Blöcke gegliedert, die direkt im Jupyter Notebook zu dokumentieren sind:

Block 1 – Use-Case-Analyse Beschreibung des Datensatzes, Formulierung der konkreten Business-Frage, Definition der Problemart (Klassifikation, Regression oder Clustering) mit Begründung, Nutzen für ein Unternehmen sowie Analyse von Risiken und ethischen/technischen Grenzen.

Block 2 – Datenprozessierung & EDA Import und Überblick (**shape**, **info**, **describe**), Qualitätsprüfung (Missing Values, Dubletten, Ausreisser) mit begründeten Bereinigungsstrategien, Explorative Datenanalyse (mindestens 3 beschriftete und interpretierte Visualisierungen), Feature Engineering (mindestens 2 neue, begründete Features) sowie Train/Test-Split.

Block 3 – Modellwahl und Training Auswahl und Begründung von 2 unterschiedlichen Modellen, kurze Funktionsbeschreibung, Training auf den Trainingsdaten und ggf. dokumentiertes Hyperparameter-Tuning. Erstellung der Vorhersagen auf dem Testset.

Block 4 – Evaluation und Fazit Berechnung der passenden Metriken für den gewählten Aufgabentyp, übersichtlicher Modellvergleich, Interpretation der Ergebnisse, Beantwortung der Business-Fragestellung und Nennung von mindestens 3 konkreten Verbesserungsmöglichkeiten.

3.3 Anforderungen an die Gesamtlösung

- Jupyter Notebook (***.ipynb**) als einziges Dokumentations- und Code-Medium
- Vollständig ausführbarer Code (**Kernel → Restart & Run All** ohne Fehler)
- Umfangreiche Markdown-Zellen zur Erklärung jeder Code-Zelle und jedes analytischen Schrittes
- Visualisierungen müssen beschriftet (Titel, Achsen) und im Text interpretiert sein
- KI-Tools sind erlaubt, müssen aber am Ende des Notebooks transparent klassifiziert/angegeben werden
- Dateibennung: **DSC_TA_Nachname_Vorname.ipynb** (Einzelarbeit) oder **DSC_TA_Nachname1_Nachname2.ipynb** (Gruppe)